TÉCNICAS ESCALABLES DE ANÁLISIS DE DATOS EN ENTORNOS BIG DATA: CLASIFICADORES

Proyecto de clasificación

Primera etapa: Resumen ejecutivo, Exploración y Preparación de datos.

02-10-2026.

Contenido

Etapas a realizar
- Resumen ejecutivo del conjunto de datos
- Exploración de datos.
- Preparación de datos.

Conjuntos de datos
Memoria
Software a entregar
¿En qué consiste el primer entregable?
¿Cómo será evaluado este primer entregable?
Fecha de entrega

Etapas a realizar

Resumen ejecutivo del conjunto de datos

Hay que proporcionar una **breve** descripción del conjunto de datos, que incluya:

- Origen de los datos, con enlace a la página que los proporciona (este enlace debe permitir descargar el mismo conjunto de datos que habéis explorado, sin ningún tipo de ambigüedad).
- Para qué se han recopilado y para qué se han usado los datos.
- Tamaño del conjunto de datos.
- Número total de atributos, indicando su naturaleza (numéricos -continuos, discretos-, booleanos, nominales) y el número de cada tipo.
- **Descripción de la clase:** etiquetas de clase y su distribución en %.

Esta **breve** descripción a veces se denomina **"Resumen ejecutivo**" del conjunto de datos. Se caracteriza por su brevedad. Es de utilidad porque proporciona de forma compacta una idea cabal de la naturaleza y la dificultad del problema. No debe superar las 500 palabras.

Exploración de datos

La exploración de datos debe cubrir, al menos, todos los aspectos que se relacionan en el **Tema 2.2, apartado 3, Exploración de datos en un problema de clasificación-I y II (pags. 33 y 34).**

Os aconsejamos dividirlo en tres subapartados:

- Descripción del problema.
- Descripción del conjunto de datos (no confundir con la breve descripción de la etapa anterior).
- Examinar correlaciones en los datos.

El objetivo es familiarizarse con los datos, describirlos en detalle e identificar todas las operaciones de limpieza que se realizarán a continuación.

En esta etapa no se puede modificar el conjunto de datos.

Preparación de datos.

Esta etapa consta de tres partes:

- Creación de conjuntos de entrenamiento y prueba.
- Limpieza de datos.
- Selección de atributos.
- Transformación de datos.

Creación de conjuntos de entrenamiento y prueba

El conjunto de prueba no puede utilizarse de ninguna forma para la creación del modelo.

Vamos a ser extremadamente rigurosos con la condición anterior.

El conjunto de prueba ha de ser sometido al mismo procesamiento que se haya realizado sobre el conjunto de entrenamiento, para que los modelos puedan clasificar sus instancias.

Nuestra recomendación es que hagáis las particiones entrenamiento/prueba después de eliminar los registros vacíos o no válidos, pero antes de realizar cualquier otra modificación. Esto os obligará a repetir parte (quizás todo) del script de limpieza, selección y transformación de datos sobre el conjunto de prueba, pero da más flexibilidad y evita un uso indebido del conjunto de prueba en la creación de los modelos.

Limpieza de datos.

Eliminar registros vacíos o no válidos, tratar los valores ausentes, inconsistentes, el ruido y los outliers.

Leer detenidamente las recomendaciones sobre las modificaciones en el conjunto de prueba como resultado de la limpieza, que se adjuntan en el apéndice I.

Selección de atributos

Se trata aquí de decidir qué atributos se van a utilizar para entrenar el modelo. Esto puede suponer eliminar algunos de los atributos originales y construir nuevos atributos, a partir de los originales, que aporten información importante para predecir la clase. Evidentemente, la selección de atributos hay que aplicarla sobre los conjuntos de entrenamiento y prueba. En el caso de que la selección sea supervisada y haya que utilizar un *estimator* sólo se pueden ajustar/entrenar (*fit*) sobre el conjunto de entrenamiento. Los modelos así ajustados se aplicarán también al conjunto de prueba.

Transformación de datos.

Incluye todas las transformaciones que consideréis necesarias realizar sobre los atributos para obtener un buen modelo, más las transformaciones necesarias para tener DataFrames con columnas *features* y *labels*.

Esta etapa puede tener cierto solapamiento con la anterior.

Los conjuntos de datos resultantes de todas estas etapas se utilizarán para la creación y evaluación de un primer modelo en el entregable individual: un árbol de decisión (**que no tenéis que realizar en este entregable; el enunciado del entregable individual ser proporcionará la semana del 12 de octubre)**.

Conjuntos de datos

El problema planteado consiste en comparar el rendimiento de dos clasificadores de **la biblioteca ML de Spark**, trabajando sobre **DataFrames**, para el conjunto de datos que se propone u otro que propongáis vosotros. En esta primera etapa sólo se construye un modelo muy básico, como comentaremos más adelante.

Este año os proponemos cinco conjuntos de datos distintos para que cada grupo elija uno, con la restricción de que no puede haber más de dos grupos trabajando sobre el mismo conjunto de datos:

1. El primer conjunto de datos propuesto fue usado en la copa KDD de 1999; tiene más de 4 millones de instancias e intenta predecir ataques a un sistema de ordenadores. El conjunto tiene 42 atributos, tanto numéricos como nominales. El problema se debe abordar como una clasificación multiclase. Puedes encontrar más información en: https://archive.ics.uci.edu/ml/datasets/KDD+Cup+1999+Data

2. El segundo conjunto de datos propuesto es el de la competición de Kaggle de estimación de la duración de un viaje en taxi en la ciudad de Nueva York. La descripción del problema la podéis encontrar en: https://www.kaggle.com/c/nyc-taxi-trip-duration. Debéis usar como conjunto de datos el conjunto de entrenamiento que proporciona Kaggle, que está formado por cerca de un millón y medio de registros y 11 atributos. En esos datos el objetivo es la predicción de la duración del viaje (***trip_duration***). Dado que buscamos construir un clasificador, debéis transformar la información de la duración del viaje en otro atributo nominal que tome valores "***short"/"medium"/"long"***, donde "***short"*** se corresponde con viajes de duración inferior o igual a 10 minutos, ***"medium"*** se corresponde con viajes de entre 10 y 25 minutos, y finalmente "***long"*** será de duración superior a 25 minutos.

3. El tercer conjunto de datos propuesto es el denominado "Census Income (KDD) Data Set": UCI Machine Learning Repository: Census-Income (KDD) Data Set. Disponéis también de información en Kaggle: Census Income Data Set | Kaggle Es un problema de clasificación binaria, consistente en predecir si los ingresos de un contribuyente superan un cierto umbral a partir de datos públicos del Censo de EEUU de 1994. Tened en cuenta que hay dos conjuntos de datos. Estos, del concurso KDD, contienen 299.285 instancias, que están descritas por 40 atributos entre nominales y numéricos, más la información de clase. Hay valores desconocidos en los atributos de algunas instancias.

4. El cuarto conjunto de datos está asociado a la clasificación de crímenes en la ciudad de Chicago en función de la información disponible en los atestados: Crimes in Chicago | Kaggle Hay cuatro ficheros de datos, debéis centraros en los crímenes ocurridos entre 2008 y 2017. Este conjunto de datos es muy rico y pueden realizarse distintos ejercicios de clasificación según el tipo de "crimen". **El grupo que elija este conjunto de datos debe analizar estos valores y proponer algún tipo de problema de clasificación, tras revisar las referencias que existen en la literatura y consultar con los profesores**, como por ejemplo clasificar en función del "primary type" en distintas categorías de crímenes. Hay 22 atributos de tipo numérico y categórico y varios millones de registros.

5. El quinto conjunto de datos está relacionado con la predicción de lluvia el día siguiente en Australia: Rain in Australia | Kaggle. El problema consiste en predecir si lloverá el día siguiente entrenando modelos de clasificación en la variable objetivo RainTomorrow (Significa: ¿llovió al día siguiente, sí o no? Esta columna es Sí si la lluvia del día siguiente fue de 1 mm o más). Este conjunto de datos contiene varios años de observaciones meteorológicas diarias de distintos lugares de Australia. Tiene más de 175.000 registros y más de veinte atributos.

Se pueden utilizar otros conjuntos de datos, siempre pidiendo que los profesores lo autoricen. En este caso hay que proporcionar una descripción básica del problema y del conjunto de datos *antes del próximo jueves día 8 de octubre*. Los criterios básicos son: más de 20 atributos, al menos dos atributos continuos, al menos dos atributos categóricos, problema de clasificación binaria o multiclase y más de medio millón de instancias.

Los conjuntos de datos 1, 2, 3 y 4 están pensados para grupos de 3 personas. El último de los conjuntos sería para grupos de 2 personas si hubiese alguno.

Una vez elegido el conjunto de datos debéis anotarlo en la wiki donde habéis puesto los integrantes de los grupos. Por lo tanto, debéis comprobar previamente que otro grupo no lo haya elegido antes.

Memoria

Además de describir el trabajo realizado, la memoria incluirá una tabla de contenidos, una breve introducción, las conclusiones, el porcentaje de trabajo y el número de horas realizado por cada estudiante, las referencias bibliográficas consultadas y los apéndices que se consideren necesarios.

No os olvidéis de poner después de las conclusiones vuestros **nombres,** la **carga de trabajo y las tareas en las que ha participado** cada estudiante.

Software a entregar

Debéis de entregar los scripts de Scala utilizados en la exploración. También los scripts/código de cualquier herramienta utilizada para realizar la exploración.

También tenéis que entregar un script de Scala que realice todas las operaciones de procesamiento y genere los conjuntos de entrenamiento y prueba transformados. Podéis organizarlo con tantos scripts como querías, con la condición de que nosotros solo tengamos que cargar un único script y que los restantes scripts estén en el directorio de trabajo.

IMPORTANTE: Los scripts de Scala han de poder ser ejecutados usando Spark 4.1.3 con el comando ":load" sin necesidad de edición por parte de los profesores, una vez descargados en nuestras máquinas virtuales. La **única** excepción es la localización del fichero de datos original. Para ello, se utilizará la variable **PATH** para indicar la ruta de acceso al fichero en la máquina local. Nosotros modificaremos el valor de esta variable para ejecutar vuestro software en nuestras máquinas. No haremos más modificaciones a vuestro software. Será motivo de penalización el incumplimiento de estos requisitos.

¿En qué consiste el primer entregable?

La memoria más el software. Todo en un fichero .zip con el nombre G*d*-E1PS, siendo *d* el número que identifica cada grupo, según consta en la Wiki donde habéis anotado previamente la composición de los grupos. Este fichero deberá ser subido ***por uno de los miembros del grupo*** a la tarea que aparecerá en el aula virtual antes de la fecha de finalización de entrega.

¿Cómo será evaluado este primer entregable?

La revisión del entregable consistirá en el análisis tanto de la calidad de la memoria como del software (guión scala que debe encargarse de la exploración inicial de los datos y, opcionalmente, otro/s guión/es en cualquier otro lenguaje que se use en la exploración detallada de los datos, especialmente visualización (por ejemplo, realización de gráficas, visualización de matrices de correlación,…)). Por lo tanto, el trabajo debe cubrir todos los aspectos que se describen en esta memoria. El peso concreto de cada uno de los apartados se os entregará una vez finalizada la entrega y antes de la revisión de dichos entregables.

Fecha límite de entrega:

19 de octubre de 2026 a las 09:00 h (hora peninsular española, CET)

Apendice I: Modificaciones en el conjunto de prueba como consecuencia de la limpieza.

En el conjunto de prueba se pueden eliminar registros vacíos o no válidos. Pero hay que ser cuidadoso al eliminar instancias del conjunto de prueba porque algún atributo tenga valores ausentes/inconsistentes o una instancia sea un outlier, porque puede sesgar la evaluación del clasificador. En su uso en el proceso de negocio, este tipo de instancias pueden aparecer, y hay que saber qué hacer con ellas.

¿Qué hacer con *los valores ausentes/inconsistentes* en el conjunto de prueba? Si en el conjunto de entrenamiento se han reemplazado por algún valor, hacer lo mismo en el de prueba. Si se han eliminado las instancias con algún atributo con valor ausente/inconsistente en el conjunto de entrenamiento, también los eliminamos en el de prueba (para que no genere error de clasificación), pero debemos contar el número total de instancias eliminadas por este motivo (*NTAIE*, *Número Total de Ausentes/Inconsistentes Eliminados*).

¿Qué hacer con los outliers en el conjunto de prueba? Podemos optar por dejarlos o eliminarlos, pero debemos contar el número total de instancias eliminadas por esta causa (*NTOE*, *Número Total de Outliers Eliminados*).

A la hora de evaluar el clasificador sobre el conjunto de prueba, habrá que proporcionar dos métricas: la tasa de error sobre el conjunto de prueba resultante después de eliminar *NTAIE+NTOE* (que es la tasa de error que proporcionan las métricas) y la tasa de no clasificados: *(NTAIE+NTOE)/(tamaño conjunto de prueba)*. **La tasa de no clasificados debe ser al menos un orden de magnitud menor que la tasa de error.**

Por lo tanto, debéis tener en cuenta estas métricas a la hora de calcular el error del clasificador en el entregable individual.